

生产级 RAG 架构演进：从手写第一个 Demo 到生产级 RAG 系统。



为什么有了大模型，还需要 RAG?

生产级 RAG 实战 · 第 1 课：RAG入门

模型负责想，搜索负责找。



贯穿全课实战：亚马逊美国站服饰箱包知识库


以真实跨境电商业务为载体，看 4 大核心岗位的日常提问



商品中心：查询商品规格、面料参数、SKU 信息（如：SKU-YG301 瑜伽裤面料是什么？）



合规风控：查询 FTC 法规、退货政策、检测标准（如：冲锋衣能不能标 Waterproof？）



尺码客服：查询美码对照表、版型差异、Inseam 数据（如：女款 Regular 腰围多少？）



店铺运营：查询运营政策、Listing 规范、季节性要求（如：Q4 退货政策延长到多久？）

直接问大模型，必然在这两个地方翻车。



知识过时。

大模型训练数据有截止日期；亚马逊退货政策、FTC 法规每季都在变，模型根本不知道最新规则。



私有知识缺失。

大模型训练集里没有你企业的质检单、打样报告、SKU 规格表；问它 SKU-JK902 的面料参数，它只能瞎猜。



微调太贵太慢，长上下文太贵还会漏看（Lost in the Middle），都不如 RAG 直接接知识库。

什么是 RAG？就是给大模型配一个专属资料员。

❌ 没有 RAG。

考生没带书进考场，
遇到不会的题只能凭记忆瞎编（幻觉）。



✅ 有 RAG。

考生带了专属资料员，
遇到不会的题先翻资料找答案，
再组织语言回答。



有了资料员，大模型到底干什么？



理解问题：
搞清楚用户到底在问什么；



抽取证据：
从检索回来的资料中提取关键信息；



逻辑推理：
基于证据做推理判断；




组织答案：
把推理结果组织成通顺的回答。




检索系统的职责只有一个：精准找到相关资料。

RAG 标准流水线全景

Offline Indexing



Online RAG





这套 RAG Demo 用了哪些技术？



开发与依赖管理：
Python 3.12 + uv



流程编排：
LangChain LCEL



向量模型：
Sentence Transformers



向量数据库：
Qdrant



关键词检索：
BM25



技术栈盘完了，下一页看向量检索在真实查询中表现如何。




向量检索很聪明，但货号、专有编码搜不到。




向量检索怎么工作。

- 文本经过 Embedding 模型转成高维向量，语义相近的内容通常更接近；
- 余弦相似度是常见的相似度计算方式，用向量方向衡量接近程度；
- 正常情况：查询 SKU-YG301 的面料规格，与产品规格书相似度 **0.89**，顺利命中。



为什么货号搜不准。

- 搜 SKU-JK902、Cordura 500D、YKK 8#，目标规格切片排到**第 40 名**；
- 通用向量模型对专有编码的区分能力有限，编码表示可能缺少足够的区分度；
- 编码在业务上全库唯一，但语义向量未必充分保留这种唯一性，因此排序可能不稳定。



BM25 + 向量混合检索：为什么两种方式天然互补？

BM25 怎么工作

- ▶ 倒排索引把词项映射到文档列表；专有编码作为完整词项时，可以直接命中。
- ▶ BM25 综合词项稀有度、词频和文档长度计算相关性。
- ▶ SKU-JK902 这类全库唯一词项通常会获得很高权重。

为什么两者互补

- ▶ 向量擅长意思相近：搜面料规格能找到 Nylon 66 + Lycra。
- ▶ BM25 擅长词项命中：搜 SKU-JK902 能直接命中。
- ▶ 两者优势互补，但并非覆盖所有失败场景。
- ▶ **RRF 融合**：把向量召回和 BM25 召回的排名转换为倒数排名分数，再求和形成综合排序。



★ 同样的货号查询，混合检索后包含目标规格的切片回到 Top-3。

RAG 入门搞定，但真实数据远没有这么干净。

📖 | 小结

RAG 把知识检索与语言生成分开：检索负责找证据，模型负责理解、判断并组织回答。

纯向量不够用，可用 BM25 与密集向量检索召回，再用 RRF 等方法融合结果。



📅 | 第 2 课预告

这节课的知识库全是干净的 Markdown，但真实世界根本没有这种好事——文档可能是 PDF、Word、Excel，里面有用信息和无用信息混在一起，还有图片、表格、公式等各种非文本内容。

下一课讲索引工程：怎么解析这些文档、怎么处理其中的非文本内容、怎么分块建索引——不同解析方式和分块方法效果差异很大。

